모델링 결과서

접수번호	접수 시 자동 발급
팀명	[팀명 기입]
공모전 중복 참여여부	[최근 3년 수상경력 기입 / 해당 없음 확인]
주요 활용 라이브러리	PyTorch, segmentation-models-pytorch, timm, NumPy, OpenCV, SciPy, scikit-image, Pillow 사전학습 encoder: EfficientNetV2-S (ImageNet-21k → 1k)

배경 및 아이디어 소개(요약)

아이디어 제안 배경

알루미늄 합금 조직을 Al, Primary Si, Al_3Ni, Eutectic Si의 네 상으로 분할한다. 실험은 얇은 Eutectic Si(E)의 누락과 Al_3Ni 혼동을 줄이는 데 초점을 맞췄다. 방향 증강으로 출발해 관찰 문맥을 넓히고, E 중심선 손실과 형태·외관 증강을 비교하면서 유효한 변경과 효과가 작은 변경을 구분했다.

파급효과

예측 마스크는 상의 면적 분율과 분포를 같은 기준으로 정량화하는 데 활용할 수 있다. 다만 특정 검증 사진에서 점수가 높았다는 사실만으로 다른 합금과 촬영 조건까지 성능을 보장하지는 않는다. 실제 적용 전에는 원본 데이터 경계를 지킨 추가 검증이 필요하다.

실험에서 얻은 결론

과거 기록에서는 D4 증강, 넓은 문맥, 중심선 보조손실과 D4 추론을 조합한 구성이 기준이 됐다. 현 PC의 복원 비교에서는 상별 스타일 교환이 80.2575%로 가장 높았다. 그러나 이 결과는 원본 valid 15장이 학습에 들어간 재분할 검증18 점수다. 원본 train70만 학습한 완료 기준모델의 valid20 점수는 78.8184%로 따로 제시한다.

이 보고서의 구성

각 단계의 표에 변경 이유, 같은 조건의 비교 기준, 측정값과 다음 결정을 함께 적었다. 원메모에 목적이 없는 경우에는 구현 원리에서 가능한 가설을 설명했으며, 당시 연구자의 의도를 확인한 기록과는 구분한다. 표의 판단은 후속 사용 여부와 관측 결과를 바탕으로 정리했다. 논문은 관련 원리의 근거로 인용하고 수치 설정의 최적성은 주장하지 않는다.

작성 기준 2026년 10월 15일
근거 승현_ 실험기록과 현 PC 코드·실측 결과·독립 검산

① 분석 개요와 ② 데이터 전처리

1-1. 분석 핵심 내용

문제는 E의 면적을 무조건 늘리는 것이 아니라, 가는 구조를 보존하면서 비슷한 외관의 다른 상과 구분하는 것이다. 따라서 전체 mIoU만 보지 않고 E IoU, 얇은 E 회수율과 E→Al_3Ni 혼동을 함께 확인했다. 중심선·문맥·형태 보존·외관 변화는 이 문제를 서로 다른 방향에서 다룬 실험이다.

1-2. 분석 배경

mIoU는 상별 겹침을 평균하므로 넓은 Al 영역만 잘 맞히는 것으로 충분하지 않다. 초기 증강 비교에서 D4는 유망했지만 밝기·소수 상 crop·복합 증강은 뚜렷한 이득이 없었다. 이후 실험에서는 구조를 보존하는 변경부터 확인하고, 변화가 큰 증강은 원인 점검용 대조군으로 다뤘다.

1-3. 분석 방법 및 데이터 활용

[표 1] 점수를 해석하기 전에 구분한 데이터 경계

구분	학습과 평가	해석 범위
과거 기록	내부 학습72 / 검증18	원본 folds.csv·초기 가중치 미복구. 과거 기록 안에서 비교한다.
현 PC 복원	학습72 = 원본 train57+valid15 검증18 = 원본 train13+valid5	80.2575%의 평가 범위. 원본 valid20 점수가 아니다.
원본 경계 재학습	원본 train70 / valid20 / test10	valid는 평가·모델 선택에만 사용. 완료 기준모델78.8184%.
추가 89장 학습	train70+valid19 / A170 한 장 제외	사용자 지정 별도 작업. 한 장 참고값86.6143%, valid20과 비교 불가.

원본 train/valid는 파일 ID·이미지 해시 중복이 없지만 A번호 7개는 양쪽에 존재한다. 원본 경계를 유지했으므로 그룹 비중복 검증이라고 설명하지 않는다. 모든 실험에서 test 정답은 없으며 test 점수도 없다. 표의 변화량은 퍼센트포인트(%p)이며, 같은 표에서 밝힌 기준에 대해서만 계산했다.

2-1. 전처리 방법

색상 마스크를 네 클래스 번호로 바꾸고 미등록 색을 검사한다. RGB 입력은 0~1 변환 후 평균0.5·표준편차0.5로 정규화한다. 영상은 bilinear, 일반 hard label은 nearest로 확대한다. 기하 softmask 실험만 one-hot 정답을 bilinear로 변환해 경계 비율을 학습 표적으로 사용한다.[8]

2-2. 전처리 절차

[표 2] 학습과 추론에서 같은 부분과 달라지는 부분

단계	학습	추론
데이터 선택	고정 train 목록에서 영상·donor 선택	valid 또는 test 원본 전체
크기·변환	native384 crop → D4 →768 확대 →기법별 증강	영상2배 확대 →최종768 타일
정답·출력	변환 후 E에서 중심선 재계산, loss·역전파	타일·D4 확률 평균 →원본 크기로 축소 →argmax

③ 모델링 첫 기준을 정한 실험

3-1. 배경과 알고리즘

U-Net은 문맥을 해석하는 경로와 위치를 복원하는 경로를 연결하므로 얇은 상과 경계를 다루는 출발점으로 삼았다.[1] EfficientNetV2-S의 사전학습 특징은 적은 영상에서 특징을 처음부터 배우는 부담을 줄이는 선택이다.[2] 전체 모델은 약2,209만 파라미터이며, 이 보고서의 실험은 해당 구조를 고정하고 학습·추론 전략을 비교했다.

3-2. 모델링 방법

처음에는 방향, 외관, 소수 상 노출 중 어느 변화가 도움이 되는지 나눠 보았다. 90° 회전·반사는 상의 상대 크기를 바꾸지 않는 방향 변화이므로, 강한 왜곡에 앞서 시험할 수 있는 기하 증강이다.[1]

[표 3] 초기 증강 비교 원본256→512 학습 tile512 no-TTA 기준76.7183%

실험	시도한 이유와 바꾼 내용	mIoU (%)	Δ (%p)	결과와 결정
추가 증강 없음 (2행)	공통 무작위 crop만 둬 추가 변환의 비교 기준을 만든다.	76.7183	기준	대조군
D4 회전·반사 (3행)	방향이 달라도 같은 상을 인식하도록 8가지 방향을 노출한다.	77.7253	+1.007	후속 기본값
약한 밝기·대비 (4행)	촬영 명암 변화에 대한 민감도를 낮출 수 있는지 확인한다.	76.8175	+0.099	뚜렷한 이득 없음
소수 상 중심 crop (5행)	작은 상을 더 자주 보여 노출 부족을 보완하려 했다.	76.7517	+0.033	뚜렷한 이득 없음
기존 복합 증강 (6행)	D4·크기·명암·노이즈·중심 crop 결합의 추가 효과를 확인한다.	76.9428	+0.224	D4보다 낮음

D4는 대조군보다 +1.007%p였고, 기록된 A그룹 bootstrap 구간도 양수였다. 다만 복합 증강보다 항상 낫다는 통계적 결론까지 확인된 것은 아니다. 이후에는 단순한 D4를 기준으로 E의 누락 원인을 따로 살폈다.

[표 4] E 누락 대응 tile512 no-TTA 앞3행 기준77.7253% 뒤2행78.0491%

실험	시도한 이유와 바꾼 내용	mIoU (%)	Δ (%p)	결과와 결정
E 중심 crop (11행)	E 경계와 명암이 겹치는 위치를 더 자주 학습한다.	77.7298	+0.004	차이 작음
경계 손실 (12행)	픽셀 분류만으로 약한 E 경계를 거리 기반 보조항으로 강조한다.[11]	77.7562	+0.031	차이 작음
문맥 확대 (13행)	native256→384로 관찰 면적을2.25배 넓혀 주변 상을 함께 본다. 입력도512→768로 조정한다.	78.0491	+0.324	후속 기준
E 중심선 recall (22행)	문맥 모델의 가는 E 골격에서 놓친 확률에 별도 손실을 준다.[3]	78.2156	+0.166	주 기준으로 사용
전체 E recall (23행)	문맥 모델에서 중심선 강조와 전체 E 가중의 효과를 구분한다.	78.1997	+0.151	대조군 유지

문맥 확대의 관측 이득은 +0.324%p로 다른 두 변경보다 컸다. 384→768 자체는 2배 확대이며 새 광학 정보를 만들지는 않는다. 앞선256→512에 비해 더 넓은 원본 영역을 보면서, 얇은 E를 큰 입력 격자로 표현한다는 두 목적을 함께 가진다.

중심선은 전체 E 대조군보다 +0.0159%p에 그쳤고 차이 구간에0이 포함됐다. 따라서 중심선의 독보적 효과로 단정하지 않는다. 같은 두 모델의 tile768 no-TTA는 각각78.3817%,78.3198%였다(28·29행).

형태와 촬영 변화 그리고 추론 방식의 비교

문맥을 넓힌 뒤에는 조직 형태·초점·외관 변화가 도움이 되는지 확인했다. 탄성 변형은 국소 형상 변화, 흐림은 광학적 선명도 변화, FDA는 저주파 외관 차이를 다루려는 시도다.[1,7] 아래 실험은 중심선 항을 더하기 전 D4+768 기준과 비교했다.

[표 5] 추가 영상 증강 동일 checkpoint를 두 타일 크기로 평가

변경	시도 이유	tile512 no-TTA	tile768 no-TTA	결과와 결정
D4+768 기준	추가 변형의 대조군	78.0491	78.1555	기준 유지
완만한 탄성 변형 34·41행	7×7 격자·σ6px로 형태 변동을 노출	78.0271	78.0332	두 조건 모두 낮음
광학 흐림 35·42행	σ0.6~1.0px로 초점 차이를 모사	78.0343	78.1601	tile768 차이+0.0046%p로 작음
학습 영상 FDA 36·43행	train donor의 저주파 진폭을 섞어 외관 변화 대응[7]	77.8847	77.8966	E 저하 기록, 미채택

증강의 일반 원리가 유효해도 이 데이터에서 이득을 주는 것은 별개였다. 여기서는 형태·명암 변형을 더하기보다 이미 학습된 중심선 모델의 방향별 예측 차이를 줄이는 추론을 먼저 확인했다.

[표 6] 추론 후보 비교 추가 학습 없음 53행은 별도 Dense-E 모델

실험	시도한 이유와 바꾼 내용	mIoU (%)	Δ (%p)	결과와 결정
tile768 no-TTA (48행)	같은 모델을 현재 평가 경로로 재추론해 비교 기준을 확보한다.	78.3826	기준	대조군
tile768 D4 TTA (49행)	회전·반사 8방향 예측을 역변환해 확률 평균한다. 방향 편차를 줄이려는 선택이다.[1]	78.9320	+0.549	채택
tile512 D4 (54행)	작은 타일로도 같은 성능을 유지하는지 확인한다.	78.7501	-0.182	768 유지
두 타일 확률 혼합 (55행)	768:512를0.75:0.25로 섞어 문맥 규모 차이를 보완한다.	78.9507	+0.019	이득 작아 미채택
입력2.25배 no-TTA (56행)	더 큰 표현이 얇은 E에 도움이 되는지 시험한다. 동일 no-TTA와 비교한다.	77.1639	-1.219	2배 유지
전체 E 모델 D4 (53행)	손실 대조군도 같은 최종 추론에서 비교한다.	78.8438	-0.088	중심선 기준 유지

D4의 +0.5494%p는 같은 모델의 no-TTA 재추론과 비교한 값이다. 기록상18장 중17장이 개선됐다. 반면 두 타일 혼합의 +0.0186%p는 구간에0이 포함됐고 연산도 늘었다. 단일 tile768·D4를 이후 기준으로 정한 이유다.

입력2.25배의 −1.2187%p는 no-TTA끼리 비교했다. 학습2배와 다른 배율에서 떨어졌다는 관측이며, 이를 D4 기준과 빼거나 배율 불일치만이 유일한 원인이라고 단정하지 않는다.

E의 누락과 혼동을 겨냥한 추가 실험

이 단계는 중심선 모델78.9320%(tile768·D4)를 기준으로 한다. E가 보이는 횟수, E가 놓이는 문맥, E와 Al_3Ni의 접경을 각각 바꾸어 누락 원인을 점검했다. 새로운 표본을 만드는 Copy-Paste의 원리는 참고하되, Al 영역에만 작은 E를 붙이는 제약은 과제에 맞춘 설계다.[9]

[표 7] crop과 상 합성 기준78.9320% 모두 tile768·D4

실험	시도한 이유와 바꾼 내용	mIoU (%)	Δ (%p)	결과와 결정
E–Al_3Ni 접경 crop (62행)	균일40%·접경40%·Ni hard-negative20%로 헷갈리는 위치를 자주 본다.	78.8754	-0.057	미채택
E 성분 문맥 합성 (63행)	작은 E를 Al 영역에 경계를 부드럽게 붙여 드문 구조·배경 조합을 늘린다.	78.9010	-0.031	미채택
E 다중 크기 crop (64행)	native336/384/432→768과 얇은 E 앵커로 규모 차이를 학습한다.	78.8844	-0.048	미채택
신규3모델 평균 (65행)	서로 다른 crop·합성 모델의 오류가 상쇄되는지 확인한다.	78.8882	-0.044	기준보다 낮음
기준+신규3 평균 (66행)	좋은 기준모델을 포함해 신규모델의 보완 가능성을 확인한다.	78.9021	-0.030	기준보다 낮음

새 표본과 앙상블이 모두 기준보다 낮았다. 다만 작은 차이만으로 각 기법이 본질적으로 해롭다고 결론내리지는 않는다. 다음에는 합성 구조 자체보다 미세조정이 기존 표현을 과하게 바꾸는지 낮은 학습률로 확인했다.

[표 8] 합성 강도와 최적화 점검 기준78.9320%

실험	시도한 이유와 바꾼 내용	mIoU (%)	Δ (%p)	결과와 결정
낮은 LR·전체 E 5epoch (71행)	encoder/decoder1e-6/1e-5로 변화 폭을 줄이고 전체 E recall로 누락 억제를 유지한다.	78.9427	+0.011	소폭 상승, 불확실
같은 설정 10epoch (72행)	초기 상승이 학습을 더 진행해도 유지되는지 확인한다.	78.9210	-0.011	지속 상승 아님

5epoch는 +0.0106%p였지만10epoch는 기준 이하였고,5epoch보다0.0217%p 낮았다. 낮은 LR와 전체 E 보조항도 함께 바뀌었으므로 합성만의 효과로 해석할 수 없다. 후속 후보로 보존하되 기준을 교체하지 않았다.

[표 9] 조명과 공동 모티프 기준78.9320% 모두 tile768·D4

실험	시도한 이유와 바꾼 내용	mIoU (%)	Δ (%p)	결과와 결정
얇은 E 국소 명암 (78행)	두께≤2px인 E의 밝기를±4~12/255로 바꿔 가시성 차이에 노출한다.	78.9096	-0.022	미채택
E 보호·주변 조명 (79행)	E와 주변3px는 유지하고 바깥 조명만 바꿔 구조 훼손을 줄인다.	78.9218	-0.010	미채택
E+Al_3Ni 모티프 (80행)	두 상이 함께 있는 실제 패치를 옮겨 자연스러운 접경을 제공한다.	78.9045	-0.028	미채택

세 전략 모두 기준을 넘지 못했다. 이 결과는 "명암을 바꾸면 좋아진다"는 넓은 가설을 지지하지 않았다. 이후에는 변형의 크기를 제한하고, 정답의 얇은 E가 변환 후에도 유지되는지 직접 검사하는 방향으로 옮겼다.

형태 보존 조건을 넣은 실험과 과거 최종 비교

얇은 상은 회전 보간에서 hard label이 잘리거나 계단 형태가 되기 쉽다. 이를 완화하기 위해 one-hot 정답도 부드럽게 변환하고, E 면적과 연결성분 수가 크게 달라지는 표본은 버리는 softmask 기하 변형을 시험했다. 외관 변화는 전체 영상 보정보다 상별 통계 교환으로 좁혔다.

[표 10] 작은 변형과 외관 보정 기준78.9320% tile768·D4

실험	시도한 이유와 바꾼 내용	mIoU (%)	Δ (%p)	결과와 결정
국소 대비·선명화 (86행)	CLAHE 등으로 작은 E 경계를 더 드러낼 수 있는지 시험한다.[12]	78.7470	-0.185	E 혼동 증가
train 명암 분포 매칭 (87행)	학습 영상의 분포 차이를 줄여 촬영 조건에 덜 민감하게 한다.	78.7911	-0.141	E 혼동 증가
E softmask 기하 (88행)	±3~7° 회전,704→768 재확대, soft GT와 E 면적·성분 검사를 결합한다.[8]	79.0072	+0.075	후속 재학습 후보
중간 주파수 진폭 (89행)	너무 저주파에만 한정하지 않고 질감 외관 변화 가능성을 시험한다.[7]	78.8886	-0.043	미채택
상별 스타일 교환 (90행)	각 상의 median/IQR을 train donor와 교환해 형태는 두고 외관만 바꾼다.[10]	78.9239	-0.008	과거에는 이득 없음

softmask가 +0.0752%p로 가장 높았지만 차이의 구간에는0이 포함됐고 얇은 E recall도 소폭 낮아졌다. 따라서 구조 보존 가설을 완전히 입증한 결과라기보다, 재학습으로 확인할 후보였다. 보간·면적·연결성 검사는 각각 경계 표적의 급격한 변화, E 소실·증가, 과도한 분절을 제한하려는 장치다.

[표 11] 10월7일 최대100epoch 재학습 기존 중심선78.9320%와 비교

실험	시도한 이유와 바꾼 내용	mIoU (%)	Δ (%p)	결과와 결정
E softmask (96행)	짧은 탐색의 최고 후보가 동일 조기종료 규칙에서도 유지되는지 확인한다.	79.0078	+0.076	과거 비교 최고
낮은 LR 문맥 합성 (97행)	초기5epoch 소폭 상승의 재현 여부를 확인한다.	78.9427	+0.011	차이 작음
중심선 재학습 (98행)	기준모델 자체의 재학습 변동을 확인하는 대조군이다.	78.9310	-0.001	기준에 근접
상별 스타일 교환 (99행)	형태를 바꾸지 않는 외관 변형을 동일 학습 규칙으로 다시 확인한다.	78.9242	-0.008	과거에는 이득 없음
E 보호 조명 (100행)	E 직접 변형을 피한 조명 변화가 더 긴 학습에서 유효한지 확인한다.	78.9217	-0.010	과거에는 이득 없음

이때 최고는 E softmask79.0078%였다. 같은 기록의 중심선 재학습78.9310%와도 차이가 작다. 과거 결과를 근거로 스타일 교환이 이미 우수했다고 쓰지 않는다. 이후 현 PC의 복원 분할에서 순위가 달라졌다는 사실을 다음 표에서 별도로 다룬다.

현 PC 복원 비교와 80.2575% 모델의 선택

처음 복원한 v1은 셀 메모를 놓쳐 WD·EMA·분할·중심선 계산 시점이 달랐다. v1 중심선77.2628%,softmask77.4996%는 원본 재현으로 볼 수 없다. 설정을 교정한 뒤 고정한 후보72/18에서5종을 다시 비교했다. 여러 조건이 동시에 바뀌었으므로 v1 대비 차이를 특정 설정의 효과로 나누지 않는다.

[표 12] 복원에서 바로잡은 설정과 그 이유

항목	수정한 내용	왜 필요한가
EMA·정규화	EMA0.999·AdamW WD0.05 복원	예측 가중치 변동과 정규화 조건을 기록에 맞춘다.[4,5]
중심선 표적	최종 변환된 E에서 skeleton→십자 팽창2회→E 내부	변형된 정답과 손실 표적의 위치를 맞춘다.[3]
공통 출발점	네 증강 분기 모두 동일 중심선 best에서 독립 시작	이전 증강의 영향이 누적되지 않게 한다. 출발 가중치 차이를 줄이는 통제다.
세부 복원 가정	cosine update 간격·최저 LR·증강 강도·검사 임계값	미확인 값을 원래 코드의 확정 설정처럼 설명하지 않는다.

[표 13] 현 PC 재분할 검증18 동일 tile768·D4 기준79.8474%

실험	시도한 이유와 바꾼 내용	mIoU (%)	Δ (%p)	결과와 결정
E 중심선 기준 (122행)	ImageNet 초기값부터 학습해 공통 출발 가중치를 만든다.	79.8474	기준	대조군
E softmask (123행)	확률0.5, E 면적비0.85~1.15·성분비0.6~1.6 조건으로 과도한 형태 변형을 제한한다.	80.0394	+0.192	+0.1920%p
낮은 LR 문맥 합성 (124행)	작은 E(4~300px), AI98% 조건, 색·경계 보정으로 부자연스러운 합성을 줄인다.	79.8459	-0.001	이득 없음
상별 스타일 교환 (125행)	확률0.47, IQR비0.75~1.25·강도0.2~0.4로 외관 변화 폭을 제한하고 GT를 유지한다.	80.2575	+0.410	관측 최고
E 보호 조명 (126행)	E 주변3px 보호, 축별±0.04×255 기울기·대비0.95~1.05로 배경만 약하게 바꾼다.	80.0431	+0.196	+0.1957%p

스타일 교환은 기준보다 +0.4102%p였다. Al/Primary Si/Al_3Ni/E IoU는92.3623/89.3216/77.6166/61.7297%였다. E만 개선하는 강한 국소 변형보다 형태를 유지한 외관 변화가 이 분할에서 더 유망했다는 관측이다. 상별 변환이 상대 밝기 순서를 반드시 보존한다거나, 이 원인이 향상의 전부라고 단정하지 않는다.

이 구현은 RGB 중앙값·사분위범위(IQR)를 쓰는 자체 증강이다. feature 평균·분산을 조절하는 AdaIN과 개념적으로 관련될 뿐 동일 구현이 아니며, Fourier 저주파 진폭을 교환하는 FDA도 아니다.[10] 55epoch EMA가 선택됐고75epoch에 조기 종료했다.

중요한 평가 한계: 이 학습72에는 원본 valid15장이 포함됐다. 따라서80.2575%는 원본 train70/valid20 결과나 대회 점수로 제출할 수 없다. 과거79.0078%와 현재80.2575% 사이를 같은 조건의 개선폭으로 연결하지 않는다.

최종 학습과 추론의 이유 그리고 성능의 적용 범위

[표 14] 최종 실행 설정과 선택 이유

설정	실제 적용	판단 근거
손실	CE+Dice+0.1×(1−E 중심선 recall)	픽셀 분류·영역 겹침·가는 E 누락을 함께 다룬다. 전체 E 문맥 분기만 dense recall.[3]
학습률	encoder3e-5 / decoder3e-4	사전학습 encoder는 작게, decoder는 상대적으로 빠르게 조정한다. 문맥 분기만1e-6/1e-5.
학습량·최적화	600patch/epoch·batch8·seed42 AdamW·EMA0.999·cosine	표본 노출·계산량을 맞추고 가중치 변동을 완화한다. cosine는 재시작 없이 후반 LR를 줄인다.[4–6]
선택·조기 종료	5epoch마다 tile512 no-TTA 최대100·patience20·minΔ0.02%p	반복 검증 비용을 줄이고 같은 규칙으로 비교한다. best는 최고점, 종료는 유의미한 개선 폭으로 판단.
최종 tile768	입력2배·768타일·반사 padding	학습 입력 크기에 맞추고 과거 작은 타일보다 높은 관측값을 반영한다.
D4·overlap0.5	8방향 역변환 확률 평균 stride384·타일 중첩 균일 평균	방향 편차·타일 경계 영향을 줄이려는 구성이다.[1] 0.5의 최적성이나 Gaussian 가중을 주장하지 않는다.
마스크 복원	확률맵 원본 크기 축소 후 argmax	연속 확률을 먼저 합친 뒤 최종 클래스만 결정한다. hard mask 다수결이 아니다.

3-3. 성능

평가는 이미지마다 TP/(TP+FP+FN)으로 상별 IoU를 구해 평균하고, 다시 이미지 수로 평균했다. 정답·예측 모두 없는 상(union=0)은 제외한다. 아래 클래스 IoU도 사진별 평균이며 전체 픽셀을 합친 global IoU와 다르다. 저장 마스크로 재계산한 점수가 결과 파일과 일치하는지 독립 검산했다.

[표 15] 완료된 두 새 실행 서로 다른 평가 집합이므로 우열 비교 금지

학습·평가 조건	mIoU(%)	Al	Primary Si	Al_3Ni	E
원본train70 / valid20	78.8184	94.1797	90.3248	73.6546	59.0676
train89 / A170 한 장	86.6143	93.7622	90.2345	90.9652	71.4952

원본 경계 기준모델은85epoch 종료·65epoch EMA 선택이다. valid20에서 E 정답 픽셀의80.09%를 E로,8.42%를 Al_3Ni로 예측했다(20장 픽셀 합산 혼동비). 가장 낮은 A71_step2_sample1은51.2626%로, 전체 평균만으로는 사진 간 편차가 가려진다. 나머지 원본 경계3기법은 최종 결과가 없어 이 모델보다 우수하다고 판단하지 않았다.

추가89장 모델은 사용자의 변경 요청에 따라 원본 valid19를 학습에 포함했다. A170은 학습·donor에서 제외하고 깨끗한 train70 기준모델에서 시작했다.45epoch 종료·25epoch 선택 후 A170 1장과 test10 추론·검산·모델 ZIP 저장을 완료했다. A170은 초기 기준모델과 이번 모델 선택에 사용됐으므로86.6143%는 단일 이미지 참고값이며 독립 test 성능이 아니다.

Test10은 정답이 없어 mIoU가 없다. 원본 크기의 예측 PNG10장을 생성했다. 학습 결과를 공유할 때에는 코드·설정·분할·가중치와 이 평가 범위를 함께 제공한다.

참고문헌과 실험 근거

인용은 기법의 원리를 뒷받침한다. 정확한 입력 크기·확률·강도의 최적성이나 이 데이터의 점수 향상을 논문이 보장하는 것은 아니다. 시도 이유는 기록된 비교 목적과 구현을 바탕으로 설명했으며, 가설과 관측 결과를 구분했다.

[1] Ronneberger et al. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. MICCAI. 문맥·위치 결합, 기하 증강, overlap-tile·회전 예측 평균.
https://arxiv.org/abs/1505.04597

[2] Tan & Le (2021). EfficientNetV2: Smaller Models and Faster Training. ICML. 효율적인 특징 추출 구조.
https://proceedings.mlr.press/v139/tan21a.html

[3] Kirchhoff et al. (2024). Skeleton Recall Loss for Connectivity Conserving and Resource Efficient Segmentation of Thin Tubular Structures. ECCV. 골격 recall·반경2·보조가중치0.1의 선례. 본 코드는 E 전용 변형.
https://arxiv.org/abs/2404.03010

[4] Loshchilov & Hutter (2019). Decoupled Weight Decay Regularization. ICLR. AdamW 정규화.
https://arxiv.org/abs/1711.05101

[5] Tarvainen & Valpola (2017). Mean teachers are better role models. NeurIPS. 가중치 EMA의 관련 근거. 본 실험은 consistency loss 미사용.
https://arxiv.org/abs/1703.01780

[6] Loshchilov & Hutter (2017). SGDR: Stochastic Gradient Descent with Warm Restarts. ICLR. cosine 감소식 참고. 본 실험은 warm restart 미사용.
https://arxiv.org/abs/1608.03983

[7] Yang & Soatto (2020). FDA: Fourier Domain Adaptation for Semantic Segmentation. CVPR. 저주파 외관 혼합의 근거. train 간 혼합·중간 주파수 변형은 원방법의 별도 응용.
https://arxiv.org/abs/2004.05498

[8] OpenCV 공식 문서. Geometric Image Transformations. bilinear·nearest 보간의 정의. 열람2026-10-15.
https://docs.opencv.org/4.x/da/d54/group__imgproc__transform.html

[9] Ghiasi et al. (2021). Simple Copy-Paste Is a Strong Data Augmentation Method for Instance Segmentation. CVPR. 객체와 정답을 함께 복사하는 증강 원리.
https://arxiv.org/abs/2012.07177

[10] Huang & Belongie (2017). Arbitrary Style Transfer in Real-Time With Adaptive Instance Normalization. ICCV. 통계 기반 외관 조절의 관련 근거. 본 구현은 RGB median/IQR.
https://arxiv.org/abs/1703.06868

[11] Kervadec et al. (2019). Boundary loss for highly unbalanced segmentation. MIDL. 영역 손실을 보완하는 거리 기반 경계 손실.
https://proceedings.mlr.press/v102/kervadec19a.html

[12] OpenCV 공식 문서. Histograms 2: Histogram Equalization. CLAHE의 국소 대비 조절과 clip limit 설명. 열람2026-10-15.
https://docs.opencv.org/4.x/d5/daf/tutorial_py_histogram_equalization.html

수치와 구현의 근거

「승현_ 실험기록」의1~101행은 과거 비교,122~126행은 현 PC 복원 비교다. 각 표의 행 번호로 원기록을 찾을 수 있다. 과거 원본 folds.csv·초기 파일은 미복구이므로 현 PC와 완전 동일한 재현이라고 설명하지 않는다.

89·90행 원메모의 참고 저자는 각각 Oh(2024), Naghizadeh(2021)다. 본문의 FDA·AdaIN 인용은 보고서에서 보완한 관련 원리 자료이며 당시 직접 참고한 논문으로 간주하지 않는다.

로컬 근거: records/source_records.json·historical_record_notes.json, src/experiment.py, configs/record_notes.json, notes_recovered/runs의 result·검산 기록, original_split_retrain 및 priority_style89_20261015의 result·verification·complete 기록.

https://docs.google.com/spreadsheets/d/1TqGmdGTCZN1NvVGDxhnaBurkkJkzj-NpITDCnAY4DQk/edit#gid=1262236171